

Presentación de la asignatura

Aprendizaje Automático Avanzado

Contenido	Página
Bienvenida a la asignatura……	3
Ubicación curricular……	3
Competencias de la asignatura……	4
Plan de la asignatura……	4
Cronograma……	7
Metodología para el desarrollo de la asignatura……	7
Evaluación y criterios generales de la acreditación……	9
Evaluación diagnóstica……	25
Frase motivadora……	35

Bienvenida a la asignatura

Se les da la más cordial bienvenida a la asignatura Aprendizaje Automático Avanzado, espacio académico en el que se explorarán modelos, algoritmos y metodologías que permiten a las máquinas aprender, adaptarse y tomar decisiones a partir de los datos. Se le invita a asumir este curso con una actitud analítica, reflexiva y proactiva, ya que cada tema representa una oportunidad para fortalecer su pensamiento crítico y sus habilidades en investigación aplicada.

El Aprendizaje Automático Avanzado constituye un eje esencial en la formación del Maestro en Inteligencia Artificial, al proporcionar las bases teóricas y prácticas necesarias para diseñar, entrenar y optimizar modelos inteligentes aplicables en diversos contextos científicos, tecnológicos e industriales.

Asimismo, esta asignatura contribuye directamente al perfil de egreso, al desarrollar competencias orientadas al diseño de soluciones innovadoras mediante el uso de modelos de aprendizaje de máquina, la integración y análisis de datos complejos en sistemas inteligentes y la evaluación del desempeño de algoritmos en entornos reales. Dichas competencias fortalecen su perfil profesional y le preparan para liderar proyectos de innovación basados en inteligencia artificial, con una visión crítica y comprometida con la transformación tecnológica.

Ubicación curricular

Esta asignatura se sitúa en el núcleo avanzado de la formación especializante, constituyéndose como pilar fundamental para el desarrollo de competencias en diseño e implementación de sistemas inteligentes. Su ubicación en el segundo semestre refleja su carácter de transición entre los fundamentos del aprendizaje automático y las aplicaciones especializadas de Inteligencia Artificial.

Se sustenta directamente en la materia básica Aprendizaje Automático (MPIAF-0103), profundizando en los paradigmas de aprendizaje y expandiendo sus aplicaciones, integra y aplica los conceptos estadísticos fundamentales, de la asignatura Modelos Estadísticos (MPIAF-0104).

Proporciona el sustento teórico-práctico indispensable para la materia de Aprendizaje Profundo (MPIAF-0202), estableciendo continuidad en el estudio de arquitecturas inteligentes complejas.

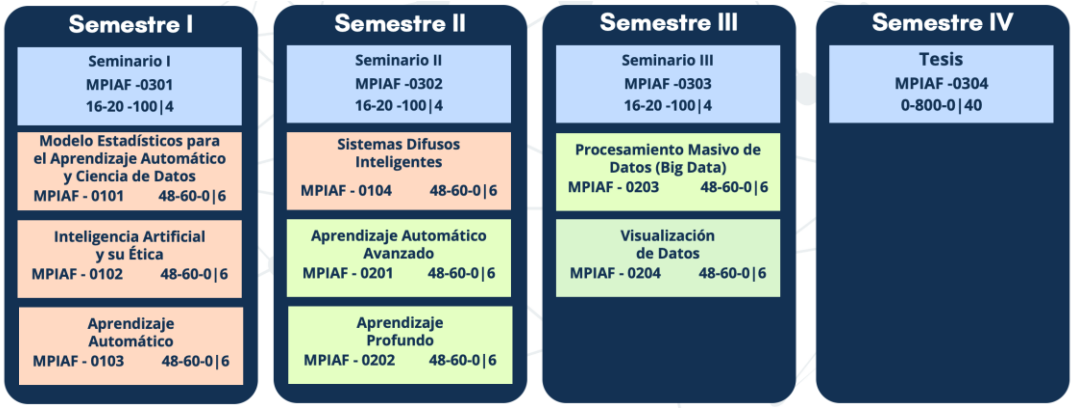
La posición estratégica de esta asignatura asegura que el estudiante:

- Consolide una comprensión profunda de los algoritmos avanzados de Machine Learning
- Desarrolle capacidad crítica para seleccionar y optimizar modelos según contextos específicos

- Adquiera competencias técnicas para la integración de *pipelines* completos de Machine Learning
- Genere prototipos funcionales que pueden evolucionar hacia proyectos de tesis aplicada

Mapa Curricular

Maestría en Inteligencia Artificial



Competencias de la asignatura

El estudiante desarrolla, entrena y optimiza modelos avanzados de aprendizaje automático, aplicando técnicas de preparación y transformación de datos para integrarlos en aplicaciones reales o simuladas mediante pipelines eficientes y despliegues escalables, asegurando interpretabilidad, eficiencia y sostenibilidad computacional en los procesos de toma de decisiones automatizadas.

Plan de la asignatura

Programa académico: Maestría en Inteligencia Artificial
Asignatura: Aprendizaje Automático Avanzado
Modalidad: No escolarizado (en línea)
Semestre: Segundo
Duración: 16 semanas

Competencia general:
Diseñar, entrenar e implementar modelos avanzados de aprendizaje automático que permitan resolver problemas complejos en entornos reales**,** integrando conocimientos teóricos, metodológicos y técnicos para desarrollar soluciones inteligentes escalables y éticamente responsables en contextos científicos, tecnológicos e industriales.

Competencias previas:

1. Aplicar fundamentos de programación y estructuras de datos para el desarrollo de algoritmos y la implementación de soluciones computacionales orientadas al procesamiento y análisis de información.
2. Emplear conocimientos de estadística, álgebra lineal y cálculo para la comprensión y formulación de modelos matemáticos asociados al aprendizaje automático y al análisis de datos.
3. Utilizar entornos y librerías de aprendizaje de máquina (como Scikit-Learn, TensorFlow o PyTorch) para el entrenamiento, validación y evaluación de modelos predictivos en contextos experimentales o aplicados.

Tabla 1. Programa de la asignatura de Aprendizaje Automático Avanzado

Unidad	Temas y subtemas	Competencia específica
1	**Fundamentos del aprendizaje automático avanzado.** 1.1 Comprender los fundamentos conceptuales y matemáticos que explican el funcionamiento de los principales paradigmas del aprendizaje automático (supervisado, no supervisado y por refuerzo). 1.2 Identificar los factores que influyen en la complejidad y rendimiento de los modelos, incluyendo el sesgo, la varianza y el sobreajuste. 1.3 Aplicar procesos de preparación, limpieza y transformación de datos para asegurar la calidad del entrenamiento y la validez de los resultados	Analizar los fundamentos teóricos, matemáticos y metodológicos del aprendizaje automático avanzado para evaluar el comportamiento, la complejidad y el rendimiento de los modelos supervisados, no supervisados y por refuerzo, aplicando técnicas adecuadas de preparación, limpieza y transformación de datos que garanticen la calidad del entrenamiento y la validez de los resultados obtenidos.
2	**Unidad 2. Aprendizaje por refuerzo profundo** 2.1 Comprender los principios del aprendizaje por refuerzo y su relación con la toma de decisiones secuenciales 2.2 Diseñar agentes inteligentes que aprendan mediante interacción con entornos simulados utilizando algoritmos como DQN y PPO. 2.3 Analizar el impacto etico y técnico del aprendizaje por refuerzo en entornos complejos como la robotica y los video juegos.	Diseñar agentes inteligentes que aprendan mediante interacción con entornos simulados, para resolver problemas de toma de decisiones secuenciales en contextos complejos como la robótica y los videojuegos, aplicando los principios del aprendizaje por refuerzo profundo y algoritmos como DQN y PPO, con una

		valoración ética y técnica de su impacto.
3	**Unidad 3. Aprendizaje no supervisado y modelos generativos** 3.1 Emplear técnicas de aprendizaje no supervisado para la extracción de características latentes y representación eficiente de datos de alta dimensionalidad (K-means y PCA) 3.2 Explorar y aplicar modelos generativos (GAN o VAE) en contextos prácticos de síntesis o aumento de datos. 3.2.1 Generar imágenes básicas con números o rostros a traves de técnicas GAN (Generative Adversarial Network) 3.2.2 Reconstruir o sintetizar datos implementado VAE (Autoencoder variacional) 3.3 Analizar los resultados obtenidos y discutir sus implicaciones técnicas y éticas.	Aplicar técnicas de aprendizaje no supervisado y modelos generativos para **extraer** características latentes, representar eficientemente datos de alta dimensionalidad y generar información sintética útil en distintos contextos, mediante el uso de algoritmos como K-means, PCA, GAN y VAE, analizando los resultados e implicaciones éticas y técnicas de su implementación.
4	**Unidad 4. Integración y despliegue de modelos inteligentes** 4.1 Diseñar pipelines de aprendizaje automático desde la carga de datos hasta la evaluación final del modelo. 4.1.1 Crear un pipeline que procese datos médicos, normalice variables, entrene una Random Forest y evalúe automáticamente la precisión. 4.2 Implementar modelos entrenados en entornos de producción o simulación mediante APIs o contenedores. 4.2.1 Desplegar un modelo de clasificación de texto que detecte lenguaje ofensivo en redes sociales, accesible desde una API o una interfaz web simple. 4.3 Evaluar el rendimiento y la escalabilidad de los modelos en entornos distribuidos o de alta demanda, considerando uso de	Implementar y desplegar modelos inteligentes en entornos de producción o simulación con el fin de asegurar su funcionalidad, eficiencia y escalabilidad en aplicaciones reales**,** mediante el diseño de pipelines completos de aprendizaje automático, el uso de APIs o contenedores, y la evaluación del rendimiento en entornos locales, distribuidos o basados en la nube.

	GPU, balance de carga y procesamiento en la nube. 4.3.1 Entrenar una red neuronal de manera local y luego ejecutarla en un entorno con GPU, midiendo diferencias en tiempo y uso recursos.	

Cronograma

Temas	Semanas															
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
Presentación de la asignatura	X															
Evaluación diagnóstica	X															
1. Fundamentos del aprendizaje automático avanzado.	X	X	X	X												
2. Aprendizaje por refuerzo profundo					X	X	X	X								
3. Aprendizaje no supervisado y modelos generativos									X	X	X	X				
4. Integración y despliegue de modelos inteligentes													X	X	X	
Evaluación sumativa													X	X	X	
Retroalimentación																X
Evaluación de la asignatura																X

Nota: La X Indica que en esa semana se llevaría a cabo la revisión y evaluación de la actividad práctica de la unidad, ya que es la que consume mayor tiempo.

Metodología para el desarrollo de la asignatura

En el Modelo de Educación a Distancia del TecNM virtual, el estudiante adquiere el compromiso de asimilar y comprender el contenido teórico y práctico, a través de los recursos educativos digitales elaborados por el personal docente, por lo cual las aulas virtuales están diseñadas para impartirse en una modalidad no escolarizada y mixta

(virtual), que combina actividades autogestivas, a través de un Sistema de Gestión del Aprendizaje, LMS por sus siglas en inglés Learning Management System y actividades entregables con retroalimentación inmediata en cada evaluación formativa y sumativa.

En esta asignatura, el docente orienta el aprendizaje hacia una comprensión profunda y aplicada del aprendizaje automático avanzado, promoviendo que el estudiante trascienda la teoría para desarrollar competencias analíticas y experimentales. El desarrollo de modelos no se limita a la comparación de algoritmos, sino que implica su aplicación práctica en casos de estudio reales, donde el estudiante analiza escenarios complejos, entrena modelos y adapta las soluciones a nuevos contextos de uso.

El enfoque formativo privilegia la experimentación, la reflexión crítica y la transferencia del conocimiento a situaciones reales. El propósito es que el estudiante evalúe con criterio profesional la pertinencia, el costo computacional y las limitaciones de los distintos enfoques algorítmicos, entendiendo sus implicaciones éticas y sociales. En este proceso, el docente actúa como guía académico y facilitador del aprendizaje, promoviendo el razonamiento autónomo, la discusión fundamentada y la capacidad de diseñar soluciones basadas en evidencia.

- Se trabajará con bibliografía actualizada, artículos científicos, materiales digitales y estudios de caso reales que sirvan como base para analizar problemas, comparar enfoques y construir soluciones algorítmicas pertinentes al contexto
- A partir del análisis crítico de la literatura técnica, se articularán debates (asíncronos) donde el estudiante deberá construir, defender y refutar argumentos sobre la superioridad o deficiencia de distintos enfoques algorítmicos.
- Se dispondrá de sesiones con el docente enfocadas en la resolución colaborativa de problemas, el diseño y ajuste de soluciones y la validación de resultados, priorizando la práctica guiada y la clarificación estratégica de dudas por encima de la exposición magistral.
- Otras actividades formativas incluyen laboratorios de implementación y un proyecto integrador, donde el estudiante implementará modelos, medirá su rendimiento, identificará riesgos y sesgos, y adaptará lo aprendido a nuevos escenarios de aplicación, demostrando transferencia del conocimiento y toma de decisiones informada.
- Las evaluaciones se basarán en el desempeño ante casos y problemas analíticos, privilegiando el juicio técnico, la argumentación y la aplicación del conocimiento sobre la memorización, con criterios explícitos de calidad, reproducibilidad e interpretación de resultados.

Evaluación y criterios generales para la acreditación

Se aplicarán los tipos de evaluación inicial o diagnóstica, formativa y sumativa en sus diferentes modalidades como lo son; autoevaluación, heteroevaluación y coevaluación.

La evaluación, así como la retroalimentación son elementos básicos que posibilitan la comunicación sobre, el qué, cómo, con qué, cuándo, el quién y el para qué de la evaluación. Los resultados permiten tomar decisiones para redireccionar el proceso de enseñanza aprendizaje, cuya finalidad es conseguir la competencia de la asignatura.

Unidad 1. Fundamentos del aprendizaje automático avanzado

Actividad	Estrategia de evaluación	Tipo de evaluación	Objetivo	Actividades por realizar	Herramientas sugeridas	Momento de evaluación	Porcentaje	Instrumento evaluación
Investigación sobre los paradigmas del Aprendizaje Automático y su impacto en la calidad del modelo	Foro	Formativa	Analizar los fundamentos teóricos y matemáticos de los principales paradigmas del aprendizaje automático (supervisado, no supervisado y por refuerzo), reflexionando sobre los factores que influyen en la complejidad y el rendimiento de los modelos, así como la importancia de la preparación y limpieza de los datos para garantizar resultados válidos.	1. Revisar y analizar el material de la unidad 1. 2. Para complementar información, investigar en fuentes académicas confiables (artículos científicos, libros especializados o documentación oficial) los tres paradigmas del aprendizaje automático: • Aprendizaje supervisado • Aprendizaje no supervisado • Aprendizaje por refuerzo 3. En tu participación inicial, redacta un texto donde:	Google académico https://www.semanticscholar.org/	Semana 1	5%	Rubrica para foro Ubicada en Anexos U1

				• expliques en qué consiste cada paradigma. • Identifiques las diferencias clave entre ellos. • Comentes cómo influye la calidad de los datos (ruido, valores faltantes, escalamiento) en el rendimiento de los modelos. • Incluyas al menos un ejemplo de aplicación para cada paradigma. 4. Incluye citas y referencias bibliográficas en formato APA al finalizar el texto de cada intervención. 5. Después de publicar tu participación, responde a 2 compañeros, aportando: • Una observación crítica • Una pregunta reflexiva • Una recomendación o sugerencia adicional (Las respuestas deben tener al menos 6 líneas cada una.)				

				6. Por último, publica una conclusión sobre lo aprendido del tema.				
Implementación y análisis comparativo de paradigmas de aprendizaje automático Modalidad individual o en equipo de 2 personas	Actividad práctica	Formativa	Aplicar modelos de aprendizaje supervisado, automático y por refuerzo en un nuevo caso de estudio, analizando los fundamentos teóricos, el comportamiento de los modelos, los factores que afectan su complejidad, y la importancia de la preparación y calidad de los datos, promoviendo la organización técnica del proyecto como parte del proceso de reproducibilidad.	1. Revisar, analizar y replicar los ejemplos de la unidad para obtener bases. 2. Selecciona uno o varios casos de estudio nuevos distintos a los mostrados en la unidad 1 para abordar cada uno de los modelos de aprendizaje: supervisado, automático y por refuerzo. Puedes usar datasets pequeños y públicos como: • UCI Machine Learning Repository • Kaggle (categorías: salud, finanzas, medio ambiente, educación) • Scikit-learn sample datasets **Requisito:** El dataset debe tener al menos 1 variable objetivo y 5 características. 3. Aplicación con Aprendizaje Supervisado • Realiza un proceso completo de preparación de datos:	Lenguaje de programación Python, R y Julia	Semana 3	15%	Lista de cotejo para Actividad práctica Rubrica para Actividad práctica Ubicada en Anexos U1

				▪ Limpieza (tratamiento de valores faltantes o ruido) ▪ Normalización o estandarización ▪ División train/test ▪ Documenta tu pipeline de preparación de datos, describiendo brevemente cada paso aplicado (qué técnicas usaste, por qué las elegiste y cómo impactan la calidad del modelo). ▪ Entrena al menos dos modelos supervisados (ej: SVM y Red neuronal) ▪ Evalúa su rendimiento utilizando: ▪ Exactitud, precisión, recall, F1-score o matriz de confusión 4. Aprendizaje automático • Basado en el ejemplo mostrado en el material de la unidad				

				1, elegir un caso de estudio distinto, y establecer el dataset de pruebas, definir sus variables • Aplicar al menos dos algoritmos PCA y Kmeans y explicar la función de cada uno en las pruebas • Identificar agrupaciones y describirlas. • Describir métricas y resultados importantes 5. Aplicación con Aprendizaje por Refuerzo • Define el entorno de aprendizaje (puede ser uno básico o un entorno OpenAI Gym). • Entrena un agente utilizando el programa base proporcionado. • Ajusta al menos un hiperparámetros principal (ej: tasa de aprendizaje, política, gamma). • Registra y grafica la evolución de la				

				recompensa acumulada. 6. Análisis Comparativo • Explica, desde el fundamento matemático y conceptual: ▪ Diferencias entre los 3 paradigmas aplicados ▪ Qué factores aumentaron la complejidad y el rendimiento ▪ Cómo influyó la calidad de los datos en los resultados del modelo supervisado • Identifica evidencias de: ▪ Sesgo ▪ Varianza ▪ Posible sobreajuste 7. **Organización y entrega del proyecto** • Entrega tu trabajo en una estructura de proyecto organizada que incluya: Portada, introducción, desarrollo,				

				conclusiones, y referencias bibliográficas, Asimismo los siguientes puntos: • Carpeta data/ con datasets originales y limpios. • Carpeta notebooks/ o scripts/ con los archivos de código. • Carpeta resultados/ con gráficas o métricas. • Archivo requirements.txt con las librerías utilizadas. • Archivo README.md breve, describiendo el proyecto, autor, dataset usado y versión del modelo.				

Unidad 2. Aprendizaje por refuerzo profundo

Actividad	Estrategia de evaluación	Tipo de evaluación	Objetivo	Actividades por realizar	Herramientas sugeridas	Momento de evaluación	Porcentaje	Instrumento evaluación
Comprender al aprendizaje por Refuerzo Profundo y su impacto en la toma de	Ensayo analítico	Formativa	Fortalecer la comprensión conceptual del aprendizaje por refuerzo profundo y su relación con la toma de decisiones secuenciales.	Elabora un ensayo analítico donde: 1. Explique con tus palabras qué es el Aprendizaje por Refuerzo (RL) y cómo	Google académico	Semana 5	10%	Lista de cotejo para ensayo analítico Rubrica para

decisiones inteligentes.				se diferencia del aprendizaje supervisado y no supervisado. 2. Describe el ciclo agente – entorno (estado → acción → recompensa → nuevo estado). 3. Explica el sentido de las tomas de decisiones secuenciales y por qué RL es adecuado para este tipo de problemas. 4. Investiga un caso real (solo uno) donde el aprendizaje por refuerzo profundo haya sido aplicado, por ejemplo: o Robots autónomos o Vehículos de conducción autónoma o Sistemas que juegan videojuegos como Atari, StarCraft, Minecraft o Go o Gestión de energía inteligente, recomendación dinámica, etc. 5. Reflexiona sobre una implicación ética relevante del caso (ej.: seguridad, manipulación, sustitución de humanos,				ensayo analítico Ubicada en Anexos U2

				sesgos, daño colateral, autonomía excesiva, etc.)				
Entrenamiento y comparación de un agente Q-Learning vs DQN en un entorno simulado Modalidad individual o en equipo de 2 personas	Reporte práctico	Sumativo	Analizar cómo cambia el comportamiento de un agente inteligente cuando se **extiende Q-Learning clásico** hacia **Aprendizaje por Refuerzo Profundo (DQN)**, observando cómo la red neuronal sustituye la tabla Q y cómo esto afecta su desempeño.	1. Selecciona el entorno (recomendación): • CartPole-v1 (mantener el poste equilibrado) • *Analizar el entorno del ejemplo de la unidad 1* 2. Ejecuta el agente de la unidad 1 con Q-Learning. • Genera la gráfica de recompensa promedio por episodio • Observa si aprende, cuánto tarda y si es estable. 3. Adapta el mismo agente a DQN (Deep Q-Network): • Reemplaza la tabla Q por una red neuronal simple (2–3 capas) • Mantén: • Mismo entorno • Misma función de recompensa • Mismo criterio de finalización	Lenguaje de programación Python, R y Julia	Semana 7	15%	Lista de cotejo para reporte práctico Rubrica para reporte práctico Ubicada en Anexos U2

				• Solo cambia la forma de aproximar Q(s, a). *DQN - Q(s,a) se predice con una red neuronal *Estados pueden ser vectores y observaciones más complejas *Aprende ajustando pesos de la red *Q-Learning clásico Q(s,a) se almacena en una tabla *Estados discretos y limitados *Aprende actualizando valores tabla 4. Entrena el agente DQN por el mismo número de episodios que el Q-Learning. 5. Genera evidencias: • Gráfica de recompensa acumulada Q-Learning vs DQN • Captura o video corto del agente actuando (puede ser una imagen por episodio) 6. Analiza y reflexiona:				

				• ¿Cuál agente aprendió más rápido? • ¿Cuál fue más estable? • ¿DQN resolvió mejor el problema o no? • Implicación ética técnica: ¿Qué significaría dejar que este agente tome decisiones reales sin supervisión?				

Unidad 3. Aprendizaje no supervisado y modelos generativos

Actividad	Estrategia de evaluación	Tipo de evaluación	Objetivo	Actividades por realizar	Herramientas sugeridas	Momento de evaluación	Porcentaje	Instrumento evaluación
Del agrupamiento a la generación: ¿Cómo aprenden los modelos sin etiquetas?”	Análisis comparativo reflexivo y mapa conceptual guiado	Sumativa	Comprender y sintetizar los principios del aprendizaje no supervisado (K-Means y PCA) **y los** modelos generativos (GAN y VAE)**,** destacando sus diferencias en propósito, fundamento matemático y aplicaciones.	**1.** Investiga los siguientes conceptos: • K-Means (agrupamiento) • PCA (reducción de dimensionalidad) • GAN (Redes Generativas Adversarias) • VAE (Autoencoders Variacionales) **2.** Elabora una síntesis analítica (1 cuartilla máximo) donde:	Coggle MindMeister Canva Miro	Semana 9	5%	Rubrica para análisis comparativo reflexivo y mapa conceptual guiado Ubicada en Anexos U3

				• Expliques qué problema resuelve cada técnica • Señales en qué consiste el proceso de aprendizaje en cada caso • Menciones en qué casos se usaría PCA antes de entrenar un modelo GAN o VAE • Identifiques una posible implicación ética del uso de modelos generativos **3.** Crea un mapa conceptual (digital, no a mano) que muestre la **relación** entre: • Datos → Aprendizaje No Supervisado → Representación Latente → Modelos Generativos **4.** Añade referencias en formato APA (mínimo 2 fuentes confiables).				
Pipeline de aprendizaje no supervisado + generación	Reporte práctico	Formativa	Aplicar técnicas de aprendizaje no supervisado para reducir	**1.** Selecciona uno de los siguientes datasets: • MNIST (números escritos a mano)	Lenguaje de programación Python, R y Julia	Semana 11	15%	Lista de cotejo para Actividad práctica

De la representación latente a la generación: Aplicación de K-Means, PCA y GAN/VAE en datos reales o sintéticos Modalidad individual o en equipo de 2 personas			dimensionalidad y extraer características latentes, y posteriormente entrenar un modelo generativo (GAN o VAE) para sintetizar datos**,** analizando la calidad y las implicaciones técnicas y éticas de los resultados.	• Fashion-MNIST (ropa) • CelebA (rostros) — opcional, requiere GPU • Otro dataset aprobado por el docente **2.** Aplicación de Aprendizaje No Supervisado • Realiza preprocesamiento y normalización • Aplica PCA para reducir la dimensionalidad (por ejemplo, de 784→50→2 dimensiones) • Aplica K-Means sobre el espacio reducido • Visualiza los clústeres y describe las características latentes observadas **3.** Aplicación de Modelos Generativos • Selecciona GAN o VAE (puedes usar código base proporcionado por el curso)				Rubrica para Actividad práctica Ubicada en Anexos U3

				• Entrena el modelo por al menos 10–50 épocas • Genera: ▪ 10 imágenes sintéticas ▪ Comparación real vs generado ▪ Gráficas de pérdida (loss function) 4. Análisis crítico • Explica qué representaciones latentes se aprendieron • Evalúa calidad de las imágenes o datos generados • Discute implicaciones éticas: ▪ Deepfakes ▪ Manipulación de identidad ▪ Propiedad intelectual de datos sintéticos				

Unidad 4. Integración y despliegue de modelos inteligentes

Actividad	Estrategia de evaluación	Tipo de evaluación	Objetivo	Actividades por realizar	Herramientas sugeridas	Momento de evaluación	Porcentaje	Instrumento evaluación

Diseño, entrenamiento y despliegue de un modelo inteligente en entorno simulado o productivo. Modalidad individual o en equipo de 2 personas	Reporte práctico	Sumativa	Diseñar un pipeline completo de aprendizaje automático, desde la carga y preparación de datos hasta el despliegue del modelo mediante una API o interfaz web, aplicando buenas prácticas de organización, documentación técnica y evaluación de rendimiento y escalabilidad.	• Elegir un tipo de modelo (según su línea o interés): • Random Forest (clasificación o regresión) • Red neuronal (simple o previamente ya trabajada en el curso) • Modelo de detección de lenguaje ofensivo / toxicidad en texto (recomendado) • Construir un pipeline completo, que incluya: • Carga de datos • Limpieza y normalización • División train/test • Entrenamiento y ajuste de hiperparámetros • Evaluación (precisión, F1-score, o métrica adecuada) • **Organiza tu proyecto en una estructura clara**, con carpetas para	Lenguaje de programación Python, R y Julia	Semana 13	30%	Listado de cotejo para documentación de reporte práctico y video de presentación Rúbrica para el reporte práctico y video de presentación Ubicada en Anexos U4

				datos, código, resultados y documentación. Incluye un archivo requirements.txt (dependencias y versiones) y un breve README.md explicando cómo ejecutar el modelo. • Desplegar el modelo mediante uno de los siguientes métodos: • API REST con FastAPI o Flask • Contenedor Docker • Simulación en entorno tipo Streamlit o interfaz web simple • Se recomienda iniciar con entornos gratuitos o simulados, como: Gradio o Streamlit Cloud. • Evaluar rendimiento y escalabilidad:				

				• Registrar tiempos de inferencia o carga • Si es posible: comparar ejecución CPU vs GPU (aunque sea simulada) • Comentar viabilidad para uso real				
	Exposición con video Modalidad individual o en equipo	Sumativa		Contenido mínimo del video 1. Contexto del caso (qué problema aborda) 2. Resumen del pipeline diseñado (flujo del modelo) 3. Datos y preparación 4. Modelo entrenado + resultados principales 5. Demostración del despliegue **(**captura o ejecución**)** 6. Conclusiones técnicas y éticas 7. Mejoras futuras	Canva, PowerPoint Teams, Meet	Semana 14	5%	Rúbrica

Evaluación diagnóstica

La evaluación diagnóstica de la asignatura Aprendizaje Automático Avanzado evalúa seis áreas esenciales que permiten determinar el nivel de preparación del estudiante antes de cursar la materia. Estas áreas incluyen: los fundamentos del aprendizaje automático y supervisado, donde se valoran los conceptos básicos de modelado y evaluación; el aprendizaje por refuerzo, que analiza la comprensión del agente, las recompensas y las estrategias de aprendizaje; el análisis descriptivo y predictivo, enfocado en la interpretación de datos y la construcción de modelos para pronosticar resultados; las matemáticas aplicadas, que revisan conocimientos de álgebra lineal, cálculo y probabilidad utilizados en la optimización de algoritmos; la limpieza y preparación de datos, centrada en el manejo de valores faltantes, codificación y escalado; y finalmente, la programación y uso de librerías de aprendizaje automático, donde se examina la aplicación práctica de herramientas como Scikit-Learn, TensorFlow y PyTorch. En conjunto, estas áreas permiten identificar las fortalezas y áreas de oportunidad del estudiante, orientando las estrategias de enseñanza hacia un aprendizaje más efectivo y especializado.

A continuación, realiza la evaluación diagnóstica con la finalidad de que reflexiones sobre tu punto de partida en cuanto a las competencias que posees y lo que la asignatura a cursar ofrece para tu formación profesional.

Cuestionario de respuesta inmediata

Fundamentos de Aprendizaje Automático y Supervisado

1. ¿Qué representa la variable objetivo en un modelo supervisado?
   A) Los datos de entrada
   B) Los parámetros internos
   C) Las etiquetas que el modelo intenta predecir
   D) El error residual
   ✅ **Respuesta: C**
2. En el aprendizaje automático, el término “overfitting” se refiere a:
   A) Entrenamiento insuficiente
   B) Modelo que memoriza los datos de entrenamiento
   C) Falta de etiquetas
   D) Uso de datos no balanceados
   ✅ **Respuesta: B**
3. En un modelo de clasificación, ¿qué métrica mide la proporción de verdaderos positivos sobre el total de positivos reales?
   A) Recall
   B) Precisión
   C) F1-Score
   D) Exactitud
   ✅ **Respuesta: A**

Aprendizaje por refuerzo

4. En el aprendizaje por refuerzo, un agente aprende mediante:
   A) Ejemplos etiquetados

B) Reglas predefinidas
C) Recompensas y castigos
D) Clasificación supervisada

✅ **Respuesta: C**

5. En una política ε-greedy, el parámetro ε controla:
   A) La tasa de aprendizaje
   B) El número de recompensas
   C) El equilibrio entre exploración y explotación
   D) El tamaño del batch

   ✅ **Respuesta: C**
6. El aprendizaje por refuerzo profundo (Deep RL) combina:
   A) Aprendizaje no supervisado y redes neuronales
   B) Aprendizaje supervisado y árboles de decisión
   C) Aprendizaje por refuerzo y redes neuronales profundas
   D) Análisis descriptivo y predictivo

   ✅ **Respuesta: C**

Análisis descriptivo y predictivo

7. El análisis descriptivo se enfoca principalmente en:
   A) Explicar por qué ocurrieron los hechos
   B) Predecir eventos futuros
   C) Describir lo que ha ocurrido
   D) Automatizar decisiones

   ✅ **Respuesta: C**
8. Un modelo predictivo con bajo error cuadrático medio (MSE) implica:
   A) Alta precisión en las predicciones
   B) Poca correlación
   C) Falta de entrenamiento
   D) Sobreajuste

   ✅ **Respuesta: A**
9. ¿Qué diferencia al análisis predictivo del prescriptivo?
   A) El predictivo explica causas
   B) El prescriptivo sugiere acciones
   C) El predictivo usa menos datos
   D) El prescriptivo ignora resultados

   ✅ **Respuesta: B**

Matemáticas aplicadas

10. En aprendizaje automático, la derivada sirve para:
    A) Calcular errores acumulados
    B) Optimizar funciones de costo
    C) Contar parámetros
    D) Normalizar datos

    ✅ **Respuesta: B**
11. ¿Qué mide la varianza de un conjunto de datos?
    A) La tendencia central
    B) El sesgo del modelo
    C) La cantidad de variables
    D) La dispersión respecto a la media

    ✅ **Respuesta: D**

Limpieza y preparación de datos

12. Los valores faltantes se pueden manejar mediante:
    A) Eliminación o imputación
    B) Aumento del error
    C) Sustitución por ceros únicamente
    D) Reentrenamiento del modelo
    ✅ **Respuesta: A**
13. La técnica “One-Hot Encoding” convierte:
    A) Datos continuos en binarios
    B) Variables categóricas en columnas binarias
    C) Valores faltantes en ceros
    D) Textos en vectores de palabras
    ✅ **Respuesta: B**

Programación y librerias de Machine Learning

14. En Scikit-Learn, la instrucción `fit()` se usa para:
    A) Evaluar el modelo
    B) Entrenar el modelo con los datos
    C) Limpiar datos
    D) Crear gráficos
    ✅ **Respuesta: B**
15. En aprendizaje automático, un pipeline permite:
    A) Automatizar el flujo desde la preparación hasta la evaluación del modelo
    B) Ejecutar modelos en paralelo
    C) Almacenar datasets
    D) Generar gráficos automáticos
    ✅ **Respuesta: A**

Banco de reactivos

Fundamentos de Aprendizaje Automático y Supervisado

1. ¿Cuál es el objetivo principal del aprendizaje automático?
   A) Memorizar datos
   B) Codificar manualmente reglas
   C) Permitir que los modelos aprendan patrones a partir de datos
   D) Generar gráficos estadísticos
   ✅ **Respuesta: C**
2. En el aprendizaje supervisado, ¿qué elemento es esencial durante el entrenamiento?
   A) Datos sin etiquetas
   B) Datos con etiquetas conocidas
   C) Parámetros aleatorios
   D) Agrupaciones automáticas
   ✅ **Respuesta: B**
3. ¿Cuál de los siguientes algoritmos es supervisado?
   A) K-Means
   B) PCA
   C) Árbol de decisión
   D) DBSCAN
   ✅ **Respuesta: C**

4. ¿Qué representa la variable objetivo en un modelo supervisado?
   A) Los datos de entrada
   B) Las etiquetas que el modelo intenta predecir
   C) Los parámetros internos
   D) El error residual
   ✅ **Respuesta: B**
5. ¿Qué tipo de salida genera un modelo de regresión lineal?
   A) Una clase
   B) Un valor numérico continuo
   C) Un clúster
   D) Un conjunto de reglas
   ✅ **Respuesta: B**
6. ¿Cuál de los siguientes modelos es apropiado para clasificación binaria?
   A) Regresión lineal
   B) Regresión logística
   C) PCA
   D) K-Means
   ✅ **Respuesta: B**
7. En el aprendizaje automático, el término “overfitting” se refiere a:
   A) Entrenamiento insuficiente
   B) Modelo que memoriza los datos de entrenamiento
   C) Falta de etiquetas
   D) Uso de datos no balanceados
   ✅ **Respuesta: B**
8. ¿Qué técnica ayuda a prevenir el sobreajuste?
   A) Aumentar el número de variables
   B) Reducir el conjunto de prueba
   C) Aplicar regularización
   D) Eliminar datos aleatoriamente
   ✅ **Respuesta: C**
9. En un modelo de clasificación, ¿qué métrica mide la proporción de verdaderos positivos sobre el total de positivos reales?
   A) Precisión
   B) Recall
   C) F1-Score
   D) Exactitud
   ✅ **Respuesta: B**
10. El conjunto de datos dividido para evaluar el desempeño del modelo se conoce como:
    A) Entrenamiento
    B) Prueba
    C) Producción
    D) Normalización
    ✅ **Respuesta: B**

Aprendizaje por refuerzo

11. En el aprendizaje por refuerzo, un agente aprende mediante:
    A) Ejemplos etiquetados
    B) Reglas predefinidas
    C) Recompensas y castigos
    D) Clasificación supervisada
    ✅ **Respuesta: C**

12. ¿Qué componente del aprendizaje por refuerzo define las posibles acciones del agente?
    A) Política
    B) Espacio de estados
    C) Espacio de acciones
    D) Recompensa
    ✅ **Respuesta: C**
13. ¿Cuál es el objetivo de una función de recompensa?
    A) Penalizar el entrenamiento
    B) Medir el desempeño del agente
    C) Normalizar los datos
    D) Dividir los estados
    ✅ **Respuesta: B**
14. En el método Q-Learning, la "Q" representa:
    A) Calidad de la acción
    B) Cantidad de datos
    C) Cuota de error
    D) Coeficiente de regularización
    ✅ **Respuesta: A**
15. ¿Cuál es la diferencia principal entre aprendizaje supervisado y por refuerzo?
    A) En el por refuerzo no existen etiquetas fijas
    B) En el por refuerzo no hay retroalimentación
    C) El por refuerzo usa solo datos categóricos
    D) El supervisado no tiene objetivo definido
    ✅ **Respuesta: A**
16. ¿Qué algoritmo combina exploración y explotación en el aprendizaje por refuerzo?
    A) DQN
    B) CNN
    C) PCA
    D) DBSCAN
    ✅ **Respuesta: A**
17. ¿Cuál de los siguientes es un entorno típico de aprendizaje por refuerzo?
    A) Clasificación de correos
    B) Juego de ajedrez
    C) Análisis de texto
    D) Agrupamiento de clientes
    ✅ **Respuesta: B**
18. En una política ε-greedy, el parámetro ε controla:
    A) La tasa de aprendizaje
    B) El número de recompensas
    C) El equilibrio entre exploración y explotación
    D) El tamaño del batch
    ✅ **Respuesta: C**
19. ¿Qué representa un episodio en el aprendizaje por refuerzo?
    A) Una iteración del entrenamiento
    B) Una secuencia completa de interacciones entre agente y entorno
    C) Una acción aleatoria
    D) Un conjunto de parámetros
    ✅ **Respuesta: B**
20. El aprendizaje por refuerzo profundo (Deep RL) combina:
    A) Aprendizaje no supervisado y redes neuronales
    B) Aprendizaje supervisado y árboles de decisión
    C) Aprendizaje por refuerzo y redes neuronales profundas

D) Análisis descriptivo y predictivo

✅ **Respuesta: C**

Análisis descriptivo y predictivo

21. El análisis descriptivo se enfoca principalmente en:
    A) Explicar por qué ocurrieron los hechos
    B) Predecir eventos futuros
    C) Describir lo que ha ocurrido
    D) Automatizar decisiones
    ✅ **Respuesta: C**
22. En el análisis predictivo, el propósito central es:
    A) Generar reportes históricos
    B) Pronosticar resultados futuros basados en datos pasados
    C) Clasificar variables cualitativas
    D) Validar hipótesis estadísticas
    ✅ **Respuesta: B**
23. ¿Qué técnica se utiliza comúnmente en el análisis descriptivo?
    A) Series temporales
    B) Histogramas y medidas de tendencia central
    C) Redes neuronales
    D) Árboles de decisión
    ✅ **Respuesta: B**
24. ¿Qué modelo se usa frecuentemente para análisis predictivo de ventas?
    A) Regresión lineal múltiple
    B) PCA
    C) K-Means
    D) DBSCAN
    ✅ **Respuesta: A**
25. La variable dependiente en un modelo predictivo es aquella que:
    A) Se controla experimentalmente
    B) Es el resultado a predecir
    C) No tiene influencia en el modelo
    D) Se usa solo para validación
    ✅ **Respuesta: B**
26. En un análisis descriptivo, la desviación estándar indica:
    A) La centralidad de los datos
    B) El grado de dispersión
    C) La precisión del modelo
    D) La tasa de aprendizaje
    ✅ **Respuesta: B**
27. Un modelo predictivo con bajo error cuadrático medio (MSE) implica:
    A) Alta precisión en las predicciones
    B) Poca correlación
    C) Falta de entrenamiento
    D) Sobreajuste
    ✅ **Respuesta: A**
28. ¿Cuál de los siguientes es un ejemplo de análisis predictivo en educación?
    A) Analizar asistencia pasada
    B) Pronosticar deserción estudiantil
    C) Contar calificaciones

D) Calcular promedios históricos

✅ **Respuesta: B**

29. ¿Qué diferencia al análisis predictivo del prescriptivo?
    A) El predictivo explica causas
    B) El prescriptivo sugiere acciones
    C) El predictivo usa menos datos
    D) El prescriptivo ignora resultados

    ✅ **Respuesta: B**
30. ¿Qué herramienta se usa con frecuencia para análisis predictivo?
    A) Excel
    B) TensorFlow
    C) Canva
    D) Illustrator

    ✅ **Respuesta: B**

Matemáticas aplicadas

31. ¿Qué representa un vector en álgebra lineal?
    A) Una matriz cuadrada
    B) Una cantidad con dirección y magnitud
    C) Una variable categórica
    D) Un valor escalar

    ✅ **Respuesta: B**
32. En aprendizaje automático, la derivada sirve para:
    A) Calcular errores acumulados
    B) Optimizar funciones de costo
    C) Contar parámetros
    D) Normalizar datos

    ✅ **Respuesta: B**
33. ¿Qué mide la varianza de un conjunto de datos?
    A) La tendencia central
    B) La dispersión respecto a la media
    C) La cantidad de variables
    D) El sesgo del modelo

    ✅ **Respuesta: B**
34. En álgebra lineal, la transposición de una matriz consiste en:
    A) Cambiar el signo de todos los elementos
    B) Multiplicar filas por columnas
    C) Intercambiar filas por columnas
    D) Elevar al cuadrado cada elemento

    ✅ **Respuesta: C**
35. ¿Cuál de las siguientes funciones de activación es más usada en redes neuronales profundas?
    A) Sigmoide
    B) ReLU
    C) Tangente hiperbólica
    D) Softmax

    ✅ **Respuesta: B**
36. El gradiente descendente busca:
    A) Minimizar la función de pérdida
    B) Maximizar la varianza
    C) Aumentar la dispersión

D) Reducir el aprendizaje

✅ **Respuesta: A**

37. En probabilidad, la suma de todas las probabilidades posibles de un evento debe ser:
    A) 0
    B) 0.5
    C) 1
    D) Variable

    ✅ **Respuesta: C**
38. La matriz de covarianza muestra:
    A) Relación entre dos variables
    B) Errores de predicción
    C) Promedios de variables
    D) Pesos neuronales

    ✅ **Respuesta: A**
39. En cálculo, la integral representa:
    A) El área bajo una curva
    B) El valor mínimo de una función
    C) El sesgo del modelo
    D) El gradiente máximo

    ✅ **Respuesta: A**
40. La normalización de datos busca:
    A) Aumentar el rango
    B) Ajustar los valores a una escala común
    C) Reducir las filas del dataset
    D) Dividir el conjunto de prueba

    ✅ **Respuesta: B**

Limpieza y preparación de datos

41. El propósito de la limpieza de datos es:
    A) Incrementar el tamaño del dataset
    B) Eliminar o corregir datos erróneos o inconsistentes
    C) Cambiar el tipo de variable
    D) Reducir la complejidad del modelo

    ✅ **Respuesta: B**
42. Los valores faltantes se pueden manejar mediante:
    A) Eliminación o imputación
    B) Aumento del error
    C) Sustitución por ceros únicamente
    D) Reentrenamiento del modelo

    ✅ **Respuesta: A**
43. ¿Qué tipo de variable requiere codificación antes del entrenamiento?
    A) Numérica
    B) Categórica
    C) Boolean
    D) Continua

    ✅ **Respuesta: B**
44. La técnica “One-Hot Encoding” convierte:
    A) Datos continuos en binarios
    B) Variables categóricas en columnas binarias
    C) Valores faltantes en ceros

D) Textos en vectores de palabras

✅ **Respuesta: B**

45. ¿Cuál es una técnica para detectar valores atípicos?
    A) Media aritmética
    B) Boxplot
    C) Normalización
    D) Regularización

    ✅ **Respuesta: B**

46. ¿Qué función de Pandas se usa para conocer los valores nulos?
    A) info()
    B) dropna()
    C) isnull()
    D) shape()

    ✅ **Respuesta: C**

47. El escalado Min-Max transforma los datos al rango:
    A) -1 a 1
    B) 0 a 1
    C) -100 a 100
    D) 1 a 10

    ✅ **Respuesta: B**

48. ¿Qué ocurre si un conjunto de datos está desbalanceado?
    A) Mejora la precisión
    B) El modelo puede sesgarse hacia la clase mayoritaria
    C) Se reduce el tiempo de entrenamiento
    D) Aumenta la varianza

    ✅ **Respuesta: B**

49. ¿Cuál de las siguientes librerías facilita la limpieza de datos?
    A) Pandas
    B) TensorFlow
    C) Matplotlib
    D) Flask

    ✅ **Respuesta: A**

50. El proceso de dividir el dataset en entrenamiento y prueba se realiza para:
    A) Incrementar el tamaño de los datos
    B) Validar la capacidad de generalización del modelo
    C) Eliminar errores de código
    D) Reducir variables

    ✅ **Respuesta: B**

Programación y librerías de Machine Learning

51. ¿Qué librería de Python se usa principalmente para aprendizaje automático tradicional?
    A) Matplotlib
    B) Scikit-Learn
    C) PyTorch
    D) Seaborn

    ✅ **Respuesta: B**

52. En TensorFlow, los modelos se construyen mediante:
    A) Series
    B) Tensores y grafos computacionales
    C) DataFrames

D) Árboles de decisión

✅ **Respuesta: B**

53. PyTorch se caracteriza por:
    A) Tener grafos estáticos
    B) Usar grafos dinámicos y operaciones en GPU
    C) No soportar redes neuronales
    D) Ser exclusivo para datos tabulares

    ✅ **Respuesta: B**

54. En Scikit-Learn, la instrucción fit() se usa para:
    A) Evaluar el modelo
    B) Entrenar el modelo con los datos
    C) Limpiar datos
    D) Crear gráficos

    ✅ **Respuesta: B**

55. ¿Qué método de Scikit-Learn se usa para generar predicciones?
    A) predict()
    B) fit()
    C) transform()
    D) compile()

    ✅ **Respuesta: A**

56. ¿Cuál es el formato más común para almacenar datasets en Python?
    A) .py
    B) .csv
    C) .exe
    D) .html

    ✅ **Respuesta: B**

57. En TensorFlow, una “epoch” representa:
    A) Un subconjunto de entrenamiento
    B) Una iteración completa sobre todo el conjunto de datos
    C) Un parámetro de la red
    D) Un valor de activación

    ✅ **Respuesta: B**

58. ¿Qué función en Scikit-Learn permite dividir los datos en entrenamiento y prueba?
    A) model_split()
    B) train_test_split()
    C) data_partition()
    D) fit_split()

    ✅ **Respuesta: B**

59. En aprendizaje automático, un pipeline permite:
    A) Automatizar el flujo desde la preparación hasta la evaluación del modelo
    B) Ejecutar modelos en paralelo
    C) Almacenar datasets
    D) Generar gráficos automáticos

    ✅ **Respuesta: A**

60. En PyTorch, los “gradients” se utilizan para:
    A) Crear nuevas variables
    B) Actualizar los pesos durante el entrenamiento
    C) Normalizar los datos
    D) Definir funciones de activación

    ✅ **Respuesta: B**

Frase motivadora
La esencia del Aprendizaje Automático Avanzado es transformar el análisis de datos complejos en soluciones a problemas reales.

Anexos

Unidad 1.
Fundamentos del aprendizaje automático avanzado

Rubrica para el foro

Criterios de evaluación		
Criterio	Descripción	Ponderación
Contenido conceptual	Claridad y precisión al explicar los paradigmas	30%
Profundidad analítica	Relación entre calidad de datos y rendimiento del modelo	25%
Ejemplos y aplicación	Pertinencia y claridad de los ejemplos presentados	15%
Participación colaborativa	Respuesta constructiva a dos compañeros	20%
Normativa de comunicación	Redacción, coherencia y referencia APA	10%

Listado de cotejo para actividad práctica

Sección	Contenido mínimo	Lista de cotejo
Portada	Nombre, institución, materia, unidad, fecha, Logos	
Introducción	Contextualización del caso de estudio y propósito del análisis	
Descripción del dataset	Fuente, variables, relevancia del problema	
Preparación de datos	Limpieza, transformación y justificación	
Resultados aprendizaje supervisado	Modelos usados, métricas, interpretación	
Resultados aprendizaje por refuerzo	Entorno, parámetros, curvas de recompensa, interpretación	
Análisis comparativo	Relación teoría–modelo–complejidad–datos	
Conclusiones	Reflexión crítica sobre desempeño y validez	
Formato	APA 7	

Rubrica para actividad práctica

Criterios de evaluación	
Criterio	Ponderación
Preparación de datos y justificación técnica	20%
Implementación del aprendizaje supervisado (correcto y evaluado)	20%
Implementación del aprendizaje por refuerzo (correcto y evaluado)	20%
Análisis comparativo conceptual y crítico	20%
Organización y documentación técnica del proyecto	15%
Presentación y referencias	5%

Unidad 2.
Aprendizaje por refuerzo profundo

Listado de cotejo para ensayo analítico

Contenido	Lista de cotejo
Portada (Nombre, institución, materia, unidad, fecha, Logos)	
Introducción	
Desarrollo del ensayo analítico	
Reflexión ética	
Conclusiones técnicas y éticas	
Mejoras futuras	

Rubrica para ensayo analítico

Criterios de evaluación	
Criterio	Ponderación
Explicación conceptual clara del aprendizaje por refuerzo	40%
Relación con toma de decisiones secuenciales	20%
Caso real correctamente explicado	25%
Reflexión ética + APA	15%

Listado de cotejo para reporte práctico

Sección	Contenido	Lista de cotejo
Portada	Nombre, institución, materia, unidad, fecha, Logos	
Introducción	Antecedente, propósito y justificación	
Descripción del entorno	Meta, estado, acciones y recompensa	
Resumen del agente Q-Learning	Comportamiento y resultados	
Resumen de la adaptación a DQN	Arquitectura de la red usada	
Comparación de resultados	Gráficas + explicación clara	
Reflexión ética	¿Qué riesgos hay en automatizar decisiones de este tipo?	
Referencias	APA 7	

Rubrica para reporte práctico

Criterios de evaluación	
Criterio	Ponderación
Funcionamiento de Q-Learning (evidencias claras)	30%
Adaptación correcta a DQN (aunque sea básica)	30%
Gráficas + comparación comprensible	25%
Reflexión ética y presentación	15%

Unidad 3.
Aprendizaje no supervisado y modelos generativos

Rubrica para análisis comparativo reflexivo y mapa conceptual guiado

Criterios de evaluación		
Criterio	Indicadores	Ponderación
Contenido conceptual	Explica correctamente K-Means, PCA, GAN y VAE, destacando su propósito y diferencia.	40%
Síntesis y relación entre conceptos	Integra ideas con lógica, muestra relación entre aprendizaje no supervisado y modelos generativos.	25%
Mapa conceptual	Representación clara y organizada, elementos jerarquizados y bien conectados.	25%
Presentación y referencias	Redacción clara, sin errores; incluye al menos 1–2 fuentes en APA.	10%

Listado de cotejo para actividad práctica

Sección	Contenido mínimo	Lista de cotejo
Portada	Nombre, institución, materia, unidad, fecha, Logos	
Introducción	Propósito, dataset y justificación	
Preprocesamiento	Limpieza, normalización y descripción de datos	
PCA + K-Means	Gráficas, interpretación, descripción de clústeres	
GAN/VAE	Arquitectura, parámetros, resultados visuales	
Análisis crítico	Calidad, limitaciones, implicaciones éticas	
Conclusiones	Reflexión sobre hallazgos	
Referencias	APA 7	

Rubrica para actividad práctica

Criterios de evaluación	
Criterio	Ponderación
Correcta aplicación de PCA y K-Means	30%
Entrenamiento y generación con GAN/VAE	30%
Interpretación conceptual y análisis crítico	25%
Claridad del reporte y APA	15%

Unidad 4.
Integración y despliegue de modelos inteligentes

Listado de cotejo para documentación de reporte práctico y video de presentación

Contenido	Lista de cotejo
Portada (Nombre, institución, materia, unidad, fecha, Logos)	
Introducción	
Contexto del caso **(**qué problema aborda**)**	
Resumen del pipeline diseñado **(**flujo del modelo**)**	
Datos y preparación	
Modelo entrenado + resultados principales	
Demostración del despliegue **(**captura o ejecución**)**	
Conclusiones técnicas y éticas	
Mejoras futuras	

Rubrica de reporte práctico + video de presentación

Criterios de evaluación			
Criterio	Actividad 1	Actividad 2	Valor total
Claridad y correcto diseño del pipeline y documentación técnica del proyecto	35%	-	35%
Entrenamiento y evaluación del modelo	25%	-	25%
Despliegue funcional (API / Contenedor / Interfaz)	20%	-	20%
Presentación y análisis crítico en el video	-	15%	15%
Referencias y presentación final	5%	5%	10%