Tecnológico Nacional de México
Instituto Tecnológico El Llano
Aguascalientes

Maestría en Inteligencia Artificial

Aprendizaje Automático Avanzado

Unidad 1. Fundamentos del aprendizaje automático avanzado

Docente

Dr. Iván Castillo Zúñiga

¡Bienvenidas y bienvenidos a la Unidad 1!

Esta unidad establece la base para comprender cómo aprende un modelo, por qué puede fallar y qué decisiones permiten obtener resultados válidos. Antes de utilizar técnicas avanzadas, es indispensable reconocer el paradigma adecuado, controlar la complejidad y preparar correctamente los datos.

Durante la unidad relacionaremos los conceptos con los casos prácticos incluidos en el documento base.

Instituto Tecnológico El Llano Aguascalientes

Contenido

1. Modelado y paradigmas
2. Factores en complejidad de modelos (generalización y sobreajuste)
3. Preparación y partición de datos

Maestría en Inteligencia Artificial

Propósito de la unidad

Analizar los fundamentos teóricos, matemáticos y metodológicos del aprendizaje automático avanzado.

Al finalizar, el estudiante podrá:

1. Diferenciar el aprendizaje supervisado, no supervisado y por refuerzo.
2. Explicar el efecto del sesgo, la varianza y el sobreajuste.
3. Preparar y separar los datos sin introducir fuga de información.

Ejemplo: antes de elegir una red neuronal, se debe precisar qué se desea predecir y qué evidencia permitirá validar el resultado.

Modelado

El aprendizaje automático transforma observaciones en una representación numérica y ajusta parámetros para optimizar un objetivo.

Representación → función objetivo → optimización → evaluación.

1. Ejemplo claro: para estimar el precio de una vivienda, x puede incluir superficie, ubicación y antigüedad; y representa el precio. El modelo ajusta θ (theta) para reducir la diferencia entre el precio estimado y el real.
2. La meta no es memorizar los ejemplos, sino responder correctamente ante viviendas nuevas.

Tres paradigmas

La señal disponible determina el tipo de aprendizaje.

Cada paradigma responde a una pregunta distinta

Paradigma	Señal	Propósito	Ejemplo
Supervisado	Etiquetas y	Predecir	Correo spam
No supervisado	Sin etiquetas	Descubrir estructura	Agrupar clientes
Por refuerzo	Recompensas	Decidir en secuencia	Ruta de un robot

Caso supervisado - suicidio

Caso de estudio del documento base: detección de cibersuicidio en páginas web.

Cada página se representa mediante frecuencias de términos; la etiqueta Correcta indica si pertenece o no al contexto.

1. El modelo aprende con ejemplos etiquetados y genera una decisión para páginas nuevas.
2. La figura muestra la clasificación temática de las palabras utilizadas como características.

Palabras clave del Suicidio



Caso supervisado – suicidio – evaluación del caso

Caso de estudio del documento base: clasificación supervisada del dataset de cibersuicidio.

La matriz de confusión permite observar no solo cuántos casos se acertaron, sino el tipo de error cometido.

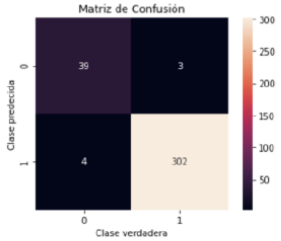
1. Resultado presentado en la unidad:
   * 39 verdaderos negativos.
   * 302 verdaderos positivos.
   * 3 falsos positivos y 4 falsos negativos.
   * Exactitud reportada: 98.0 %.

   Interpretación: siete errores sobre 348 casos de prueba.

Resultados de clasificación

Ajusta el modelo de datos al proceso de entrenamiento
/Users/ivancastillozuniga/opt/anaconda3/lib/python3.8/
ConvergenceWarning: Stochastic Optimizer: Maximum it
  warnings.warn(
MLPClassifier()

MATRIZ DE CONFUSIÓN



Descripción
Verdaderos Negativos: 39
Verdaderos Positivos: 302
Falsos Positivos: 3
Falsos Negativos: 4

RESULTADOS DE CLASIFICACIÓN

Porcentaje de precisión: 98.0 %
Errores de clasificación: 7 errores, sobre un total de 348
Tiempo de ejecución es de: 3.37 seg

No supervisado

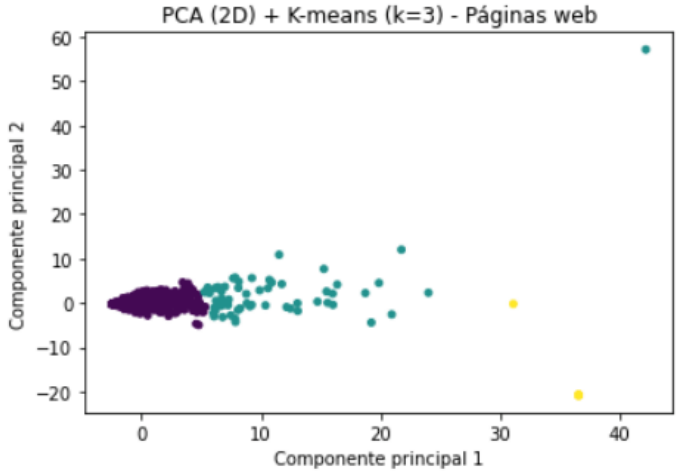
Caso de estudio
PCA y k-means sobre las páginas web.

PCA reduce las 97 características a dos componentes para visualización; k-means forma tres grupos sin utilizar la etiqueta Correcta durante el agrupamiento.

1. Ejemplo de interpretación: un grupo puede concentrar páginas con términos similares, pero el investigador debe analizar sus palabras predominantes antes de asignarle un significado.

Resultados de clasificación

```
0    1091
1      60
2       6
dtype: int64
```




```
Top 10 términos por frecuencia promedio en cluster 0:
```

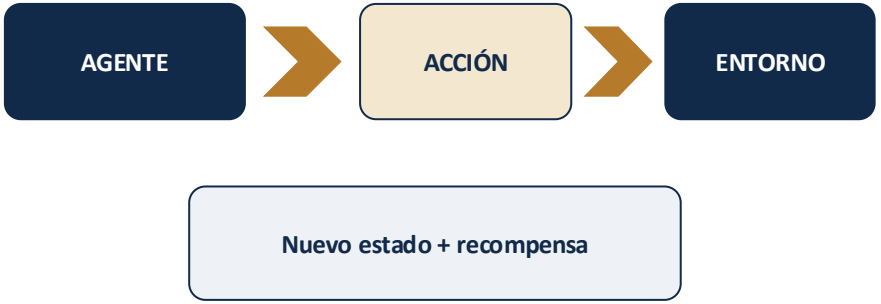
Por refuerzo

Caso de estudio del documento base: Q-learning en el entorno FrozenLake.

El agente observa un estado, elige una acción y recibe una recompensa. Mediante episodios sucesivos actualiza su política para aumentar el retorno esperado.

1. Resultado de la unidad: tasa de éxito aproximada de 74.5 % en 200 episodios de prueba.
2. Ejemplo: caer en un agujero termina el episodio; llegar a la meta produce la recompensa que orienta el aprendizaje.

Ciclo de interacción



La retroalimentación modifica la política

Sesgo y varianza

Caso de estudio del documento base: árboles de decisión con distintas profundidades.

Profundidad 1: modelo simple y mayor sesgo.

1. Profundidad 3: mejor equilibrio.
2. Profundidad 10 o sin límite: el entrenamiento mejora, pero la prueba deja de mejorar.
3. La comparación evidencia que aumentar la complejidad no garantiza una generalización superior.

Resultados del programa

```
Profundidad=1
  Exactitud entrenamiento: 0.870
  Exactitud prueba:        0.899
----------------------------------------
Profundidad=3
  Exactitud entrenamiento: 0.959
  Exactitud prueba:        0.943
----------------------------------------
Profundidad=10
  Exactitud entrenamiento: 0.999
  Exactitud prueba:        0.971
----------------------------------------
Profundidad=None
  Exactitud entrenamiento: 1.000
  Exactitud prueba:        0.971
----------------------------------------
```

Sobreajuste

Ocurre cuando el modelo aprende detalles y ruido del entrenamiento, pero pierde desempeño ante datos nuevos.

Señal principal: exactitud muy alta en entrenamiento
y claramente menor en validación o prueba.

1. Ejemplo claro: un árbol sin límite memoriza excepciones de 100 alumnos y obtiene 100 % en entrenamiento; al evaluar otro grupo, baja a 72 %.
2. Cómo reducirlo: validación cruzada, regularización, poda, detención temprana, más datos o menor complejidad.
3. La prueba final debe permanecer aislada hasta concluir el ajuste.

Preparación de datos

La calidad del modelo depende de la calidad y del tratamiento de los datos.

Ejemplo: si la edad aparece como 25, “25 años” y 250, el algoritmo interpreta tres valores distintos. Antes de entrenar, deben corregirse formato y valor atípico.



Proceso fundamental antes del entrenamiento

Caso de preparación

Caso de estudio del documento base: preparación del dataset de cibersuicidio.

El ejemplo inspecciona valores faltantes, imputa con la estrategia más frecuente, estandariza las variables y después realiza la separación estratificada.

1. La captura se incluye como evidencia del procedimiento; en una aplicación real conviene encapsular estas operaciones en un pipeline para evitar inconsistencias.

Resultados

```
# 3) Inspección rápida
print(X.isnull().sum().head())

# 4) Limpieza: imputación de valores faltantes (si existen)
imputer = SimpleImputer(strategy="mean")
X_imputed = imputer.fit_transform(X)

# 5) Transformación: escalamiento de variables
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X_imputed)

# 6) Separación entrenamiento / prueba
X_train, X_test, y_train, y_test = train_test_split(
   X_scaled, y, test_size=0.3, random_state=42, stratify=y
)

print("Datos listos para entrenamiento y evaluación")
```

Resultados del programa

```
suicidio      0
```

Partición sin fuga

Primero se separan los datos; después, las transformaciones se ajustan únicamente con entrenamiento.

Ejemplo claro: calcular la media de todas las observaciones antes de dividir permite que la prueba influya en el escalamiento. La métrica resultante será optimista.

1. Entrenamiento ajusta parámetros; validación selecciona; prueba estima el desempeño final.



No ajustar transformaciones con validación o prueba

Síntesis y aplicación

Un modelo confiable integra tres decisiones: paradigma adecuado, complejidad controlada y datos preparados sin fuga de información.

Actividad de cierre: seleccione un problema real y justifique (1) paradigma, (2) representación de los datos, (3) métrica principal, (4) riesgo de sobreajuste y (5) estrategia de partición.

Ejemplo: en la predicción de abandono escolar, indique qué variables usaría, cuál sería la etiqueta y qué error tendría mayor impacto.

Pregunta guía: ¿qué evidencia demostraría que el modelo generaliza?

Actividades para desarrollar en la unidad 1 – semana 1

1.1 Foro: Investigación sobre los paradigmas del aprendizaje automático (supervisado, no supervisado y por refuerzo) y su impacto en la calidad del modelo – individual.

1.2 Actividad documentada: Implementación y análisis comparativo de paradigmas de aprendizaje automático (supervisado, no supervisado y por refuerzo) – individual o por equipo de 2 personas.

Castillo-Zúñiga, I. et al. (2022). Clasificación de características asociadas al cibersuicidio. [Referencia incluida en el documento base].

Géron, A. (2022). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (3rd ed.). O'Reilly.

Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning (2nd ed.). Springer.

Mitchell, T. M. (1997). Machine Learning. McGraw-Hill.

Sutton, R. S., & Barto, A. G. (2018). Reinforcement Learning: An Introduction (2nd ed.). MIT Press.